— ЛОКАЛЬНЫЙ РАНТАЙМ

Quark Runtime

Рантайм, который сам подбирает модель под железо: осматривает ПК, считает бюджет памяти, запускает Ollama и отдаёт OpenAI-совместимый API.

6

моделей в каталоге

ОТ 0.6B ДО 8B

4

экрана

ПК · МОДЕЛЬ · ЗАПУСК · ПРОВЕРКА

5

МБ приложение

PORTABLE · NO ADMIN

Выполнил: Серенко Никита Алексеевич · РП.09.25.1

Руководитель: Надымов Александр Васильевич

— 01 / АКТУАЛЬНОСТЬ

Нейросети нужны там, где нет ни GPU, ни интернета.

Облако недоступно или запрещено, а локальные модели либо не влезают в память, либо работают слишком медленно.

01

Нет GPU

Офисные и учебные ПК: 4 ядра, 8–16 ГБ, без видеокарты.

02

Нет интернета

Данные нельзя выносить, облако запрещено или недоступно.

03

Нет специалиста

Пользователь не знает, какую модель выбрать и сколько ждать.

Пользователь остаётся один на один с выбором модели.

— 02 / ЦЕЛЬ И ЗАДАЧИ

Цель — запускать нейросеть на слабом ПК без специалиста.

Объект — локальный запуск моделей на слабом железе. Предмет — выбор модели и прогноз скорости. Методы — профилирование, расчёт, эксперимент.

01

Профиль

Процессор, память, GPU, диск.

02

Бюджет

Сколько памяти можно отдать модели.

03

Подбор

Каталог из шести моделей и прогноз.

04

Запуск и API

Своя Ollama и OpenAI-совместимый шлюз.

Четыре задачи — один работающий рантайм.

— 03 / ИДЕЯ

Quark считает до скачивания.

Один цикл: осмотреть машину, посчитать бюджет, подобрать модель, запустить движок, замерить и отдать API.

01

Осмотреть ПК

CPU, ядра, AVX2, ОЗУ, скорость памяти, GPU, диск, питание.

02

Посчитать бюджет

Сколько памяти можно отдать модели, не уронив систему.

03

Подобрать модель

Каталог из шести моделей, фильтры по памяти и скорости.

04

Запустить Ollama

Своя копия на 11435, своя папка моделей, без админа.

05

Замерить

Реальный бенчмарк и калибровка прогноза.

06

Отдать API

OpenAI-compatible шлюз на 127.0.0.1:11500.

Один цикл — и его можно повторить на любом железе.

— 04 / ПРОГРАММНАЯ РЕАЛИЗАЦИЯ

Rust + Tauri: четыре модуля, один бинарник.

Rust для ядра, Tauri 2 для окна, HTML/JS для интерфейса. Всё в одном процессе, без облака.

hardware.rs

Профиль

CPU, AVX2, ОЗУ, скорость памяти, GPU, диск.

plan.rs

План

Бюджет, каталог, фильтры, прогноз, калибровка.

runtime.rs

Движок

Своя Ollama, pull, прогрев, бенчмарк, doctor.

gateway.rs

Шлюз

OpenAI API, токен, SSE, эмбеддинги.

СТЕК И РЕЛИЗ

5,09

МБ · QUARK.EXE

Rust — память без GC, один бинарник

Tauri 2 — WebView2, без Chromium

HTML/CSS/JS — четыре экрана

Ollama — HTTP + JSON-схема

OpenAI API — шлюз на 11500

Один бинарник, четыре экрана, ноль облачных запросов.

— 05 / МЕТОД

Бюджет, фильтры, сортировка.

01 / БЮДЖЕТ

Сколько памяти можно отдать

`min(доступно - 1,5 ГБ, всего × 0,7)`

GPU ≥ 6 ГБ → VRAM × 0,85

Системе остаётся запас. Модель не должна вытеснить Windows в своп.

02 / ФИЛЬТРЫ

Что имеет смысл запускать

Влезает в контекст 2048. Прогноз не ниже 4 ток/с; без AVX2 — 6. Всё остальное отсекается до скачивания.

03 / СОРТИРОВКА

Что рекомендовать

`quality + ru_quality × 2`

УРОВНИ: ЛЁГКИЙ · СРЕДНИЙ · МОЩНЫЙ

ОРИЕНТИРОВОЧНЫЙ ПОДБОР

8 ГБ ОЗУ	0.6–2B	лёгкие модели
16 ГБ ОЗУ	4B	баланс
32 ГБ ОЗУ	8B	умнее, но медленнее
GPU 8–24 ГБ	8B	30–70 ток/с

Диапазоны зависят от памяти, ядер и модели.

Бюджет — это не «сколько свободно», а «сколько можно забрать».

— 06 / ЭКСПЕРИМЕНТ

Прогноз сходится с фактом.

ПРОГНОЗ ≈ ФАКТ

Ошибка на тестовом стенде — в пределах 5%.

3 ПРОХОДА · МЕДИАНА · ПРОГРЕВ НЕ СЧИТАЕТСЯ

3	±5%	1
прогона, медиана ПРОГРЕВ НЕ СЧИТАЕТСЯ	ошибка прогноза НА ТЕСТОВОМ СТЕНДЕ	калибровка k НА КОНКРЕТНОЙ МАШИНЕ

ФОРМУЛА

```
ток/с ≈ скорость_памяти / размер_модели × k
```

k калибруется реальным замером и хранится в settings.json. Поэтому прогноз привязан к конкретной машине, а не к «среднему компьютеру».

— 07 / РЕЗУЛЬТАТЫ

Что это даёт на практике.

ОРИЕНТИРОВОЧНЫЕ КЛАССЫ ЖЕЛЕЗА

8 ГБ ОЗУ	0.6–2B	лёгкие модели, ~4–6 ток/с
16 ГБ ОЗУ	4B	баланс, ~5–7 ток/с
32 ГБ ОЗУ	8B	умнее, ~2–4 ток/с на CPU
GPU 8–24 ГБ	8B	30–70 ток/с

Диапазоны зависят от памяти, ядер и модели. Прогноз уточняется калибровкой.

— 08 / ВЫВОДЫ

Что получилось.

Считает до скачивания

Профиль железа, бюджет памяти и прогноз скорости — до первого гигабайта загрузки.

прогноз проверен

Запускает сам

Своя Ollama на 11435, своя папка моделей, прогрев, бенчмарк и диагностика. Без админа.

5 МБ · portable

Отдаёт наружу

OpenAI-совместимый шлюз на 127.0.0.1:11500. Любой клиент, который умеет OpenAI.

/v1/chat/completions

Это не чат. Это слой между железом и моделью.

Итог: работающий рантайм на слабой машине, а не концепция.

— 09 / ПРАКТИЧЕСКОЕ ПРИМЕНЕНИЕ

Где это нужно.

Один и тот же рантайм — от школьного ПК до рабочей станции.

01 / ШКОЛА И БИБЛИОТЕКА

Нет интернета

Документы, текст, вопросы по инструкции.

02 / ОФИС И ПРОИЗВОДСТВО

Данные не выносим

Локальный API для внутренних инструментов.

03 / РАЗРАБОТКА

OpenAI-compatible

Open WebUI, VS Code, Python.

01 / ВАШ ПК

Профиль и бюджет

02 / РЕКОМЕНДАЦИЯ

Модели и скорость

03 / ЗАПУСК

Движок и API

04 / ПРОВЕРКА

Ответ и график

Один и тот же рантайм — разные сценарии.

— 10 / РАЗВИТИЕ

Что дальше.

Развитие идёт в сторону удобства, автоматизации и более широкого железа.

01 / УСТАНОВКА

NSIS-установщик и экран настроек.

Обычный setup.exe, тема, токен, автозапуск.

02 / МОДЕЛИ

Менеджер моделей.

Удаление, импорт GGUF, место на диске.

03 / ОБЛАКО

Облако как второй бэкенд.

Режим «Офлайн / Гибрид».

04 / АВТОТЮНЕР

Автотюнер.

Потоки, batch, KV, flash attention.

05 / БЭКЕНД

Другие бэкенды.

llama.cpp, спекулятивное декодирование, LoRA, GBNF, KV-кэш на диск.

Следующий шаг — не новая модель, а удобство и автоматизация.

— 11 / ИСТОЧНИКИ

Список источников.

01 Ollama. Documentation. ollama.com/docs

02 Qwen Team. Qwen3 Technical Report. 2025.

03 Meta AI. Llama 3.1 Model Card. 2024.

04 Google DeepMind. Gemma 2 Model Card. 2024.

05 Tauri. Documentation. tauri.app

06 The Rust Programming Language. doc.rust-lang.org/book

07 OpenAI. API Reference. platform.openai.com/docs

08 Microsoft. Job Objects. Windows documentation.

Спасибо за внимание.

Серенко Н.А. · РП.09.25.1 · Надымов А.В.